As músicas populares de diferentes países estão ficando semanticamente parecidas? Uma análise de letras via embeddings

Felipe Dias, Lean Henrique Pereira, Luiz Felipe Lima e Wiliam Ventura
Universidade Federal de Minas Gerais (UFMG) – Belo Horizonte, MG – Brasil
Disciplina: Computação Social – Relatório Final

Resumo. Investigamos se as músicas mais ouvidas em seis países (EUA, Brasil, México, Espanha, Austrália e Japão) estão ficando semanticamente mais parecidas entre 2017 e 2025. Com 2.156 letras do top 40 anual do Spotify, representadas por embeddings multilíngues e agrupadas em cinco clusters, medimos a similaridade entre países pela divergência de Jensen–Shannon e pelo cosseno entre centroides. Não encontramos homogeneização global: a similaridade média cai de 0,64 para 0,47, mas essa queda se concentra em 2017 e acompanha a redução dos hits compartilhados entre países. O Japão se afasta dos demais, enquanto EUA, Brasil, México e Espanha permanecem estáveis. Ao traduzir as letras para o inglês, a divergência global desaparece e surge convergência no bloco ocidental, o que indica que o idioma explica boa parte da distância observada.

1. Introdução

A conectividade global do streaming levanta uma questão clássica da Computação Social: a cultura online se homogeneíza ou preserva as diferenças locais? Estudos com atributos de áudio apontam tanto homogeneização [6, 4] quanto aumento da diversidade entre países [1], mas pouco se sabe sobre o **conteúdo semântico das letras**. Perguntamos se as músicas populares de diferentes países estão ficando semanticamente mais parecidas ao longo do tempo. Mantivemos as hipóteses exploratórias da proposta: **H1**, convergência parcial entre os países fortemente conectados à indústria global (EUA, Brasil, México e Espanha), e **H2**, distanciamento do Japão, país com forte identidade linguística local.

2. Dados e Métodos

Dados. Para cada país e ano de 2017 a 2025, as 40 primeiras faixas do ranking anual do Spotify Charts formam uma célula país $\times$ ano, totalizando 2.156 faixas (cerca de 360 por país e 240 por ano). Em relação à proposta, a Coreia do Sul foi substituída pela Austrália e a janela passou de cinco para nove anos. Os idiomas predominantes são inglês (849 faixas), espanhol (680), português (331) e japonês (289). Cada letra foi vetorizada com os modelos pré-treinados multilíngues LaBSE [2] e multilingual-e5, via biblioteca de embeddings de sentenças [5], sem treinamento de modelos próprios. Escolhemos esses modelos porque mapeiam letras de diferentes idiomas para o mesmo espaço vetorial, sem depender exclusivamente de tradução prévia. Apenas os vetores foram armazenados.

Clusterização. Os vetores foram reduzidos com UMAP e agrupados com K-Means, com k escolhido por silhueta, e os clusters foram interpretados por termos característicos [3]. Para cada país a e ano t, $p_{a,t}$ é a distribuição de suas músicas sobre os clusters. A similaridade entre a e b é $1 - \mathrm{JS}(p_{a,t}, p_{b,t})$, com JS em base 2 (valores em $[0,1]$), complementada pelo cosseno entre os centroides dos embeddings. A *similaridade cultural global* S_t é a média sobre os 15 pares de países. S_{H1} usa os 6 pares entre EUA, Brasil, México e Espanha, e S_{H2} os 5 pares do Japão com os demais países (a Austrália fica fora de H1 e de H2, mas entra em S_t e nas análises por par).

Inferência. Como há apenas nove pontos no tempo, a tendência é medida pela inclinação de uma regressão linear sobre o ano e pela correlação de Spearman (ρ). Os intervalos de confiança (IC95%) vêm de bootstrap, com reamostragem das músicas dentro de cada célula. Um resultado é lido como convergência ou divergência quando o IC exclui zero e o p da regressão é menor que 0,05, e como *fraco* quando só o IC exclui zero. Um teste de permutação dos rótulos de país (999 permutações) mede quanto a similaridade observada difere da esperada se o país não importasse. Os controles são: (a) excluir 2017, ano com muitos hits compartilhados; (b) usar apenas músicas exclusivas de cada país; e (c) repetir tudo com as letras traduzidas para o inglês.

3. Resultados

3.1 Estrutura semântica

A silhueta é máxima em $k = 5$ (0,48) e decresce com k, com um novo patamar abaixo de 0,32 a partir de $k = 18$; $k = 5$ é, porém, o limite inferior da busca (5 a 25). A Tabela 1 e a Figura 1 mostram que os clusters seguem fortemente o idioma e a região. O cluster 0 reúne português e espanhol (Brasil, México e Espanha), o

4 é majoritariamente espanhol, os clusters 1 e 2 são em inglês (EUA e Austrália) e o 3 é quase todo japonês. O cluster 2 se distingue pelo vocabulário explícito típico do rap. Brasil, México e Espanha dividem-se entre os clusters 0 e 4 (68%/26%, 40%/51% e 28%/65%), e o Japão concentra 73% de suas faixas no cluster 3.

Tabela 1: Clusters ($k = 5$): tamanho, idiomas e países dominantes.

Cluster	Faixas	Idiomas	Países	Perfil
0	428	pt 53%, es 43%	Brasil 47%, México 28%, Espanha 20%	pop/balada latino
1	229	en 97%	Austrália 46%, EUA 33%, Japão 10%	pop romântico em inglês
2	194	en 92%	EUA 50%, Austrália 34%, Japão 6%	hip-hop/rap explícito
3	161	ja 97%	Japão 100%	música japonesa
4	432	es 69%, pt 21%, en 8%	Espanha 39%, México 31%, Brasil 16%	pop em espanhol

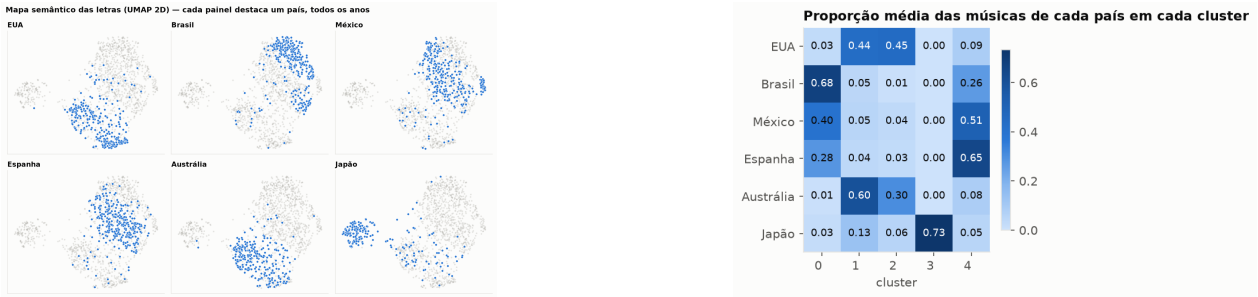


Figura 1: Esquerda: mapa UMAP das letras, destacando um país por painel. Direita: proporção média das músicas de cada país em cada cluster.

3.2 Similaridade cultural global

A Figura 2 mostra que S_t cai de 0,64 (IC95% [0,57; 0,70]) em 2017 para 0,52 em 2018 e oscila entre 0,44 e 0,50 de 2019 a 2025 (0,47 em 2025). A inclinação é de $-0{,}0165$ por ano (IC95% $[-0{,}025; -0{,}008]$, $p = 0{,}013$, $\rho = -0{,}83$), isto é, divergência. Pelo cosseno, a queda também se concentra em 2017–2018 (0,95 para 0,92) e depois estabiliza em torno de 0,91, e a divergência é fraca ($-0{,}0022$ por ano, IC excluindo zero, mas $p = 0{,}18$). Sem 2017, a tendência em $1-$JS deixa de ser clara ($-0{,}0085$, IC $[-0{,}019; 0{,}002]$) e o cosseno fica plano ($+0{,}0003$). Mais importante, os países são muito mais distintos do que o acaso permitiria: o valor esperado se o país não importasse é cerca de 0,96 em $1-$JS e 0,98 no cosseno, contra os 0,44–0,64 e 0,91–0,95 observados, com $p \approx 0{,}001$ (o mínimo possível com 999 permutações) em todos os anos.

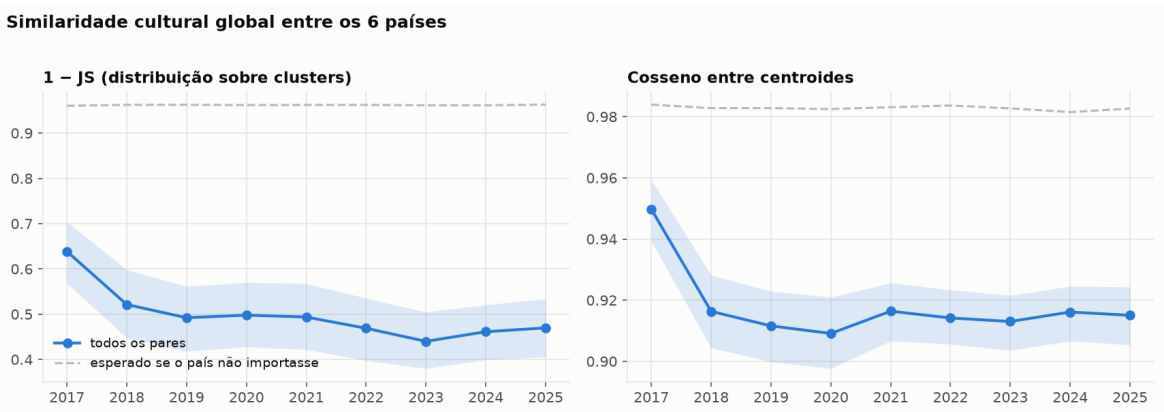


Figura 2: Similaridade cultural global S_t (média dos 15 pares) com IC95% por bootstrap, e valor esperado sob permutação dos rótulos de país (tracejado).

3.3 Pares de países e comunidades

A Figura 3 mostra uma estrutura em dois blocos. Dentro deles a similaridade é alta: México–Espanha (0,97), EUA–Austrália (0,95), Brasil–México (0,92) e Brasil–Espanha (0,85). Entre blocos é baixa, de 0,30 a 0,43, e a menor ocorre entre Japão e os países latinos (0,25 a 0,28). Nenhum dos pares dentro dos blocos tem tendência clara. As únicas divergências com IC excluindo zero e sem ressalva envolvem o Japão e os países

latinos: Espanha–Japão ($-0{,}055$ por ano), México–Japão ($-0{,}052$) e Brasil–Japão ($-0{,}044$). EUA–Japão, Austrália–Japão e os pares da Austrália com México e Espanha divergem apenas de forma fraca (IC exclui zero, mas sem sustentação na regressão). A detecção de comunidades de Louvain separa Brasil, México, Espanha de EUA, Austrália em todos os anos, e o Japão muda de lado: junta-se aos anglófonos em 2017 e de 2021 a 2025, aos latinos em 2018–2019 e fica isolado em 2020. Como todos os laços do Japão são fracos (0,25 a 0,39), essa atribuição é instável. Os laços com os países latinos são os que mais enfraquecem, e por isso o Japão tende a ficar no bloco anglófono, onde seu vínculo mais forte é com a Austrália (0,39).

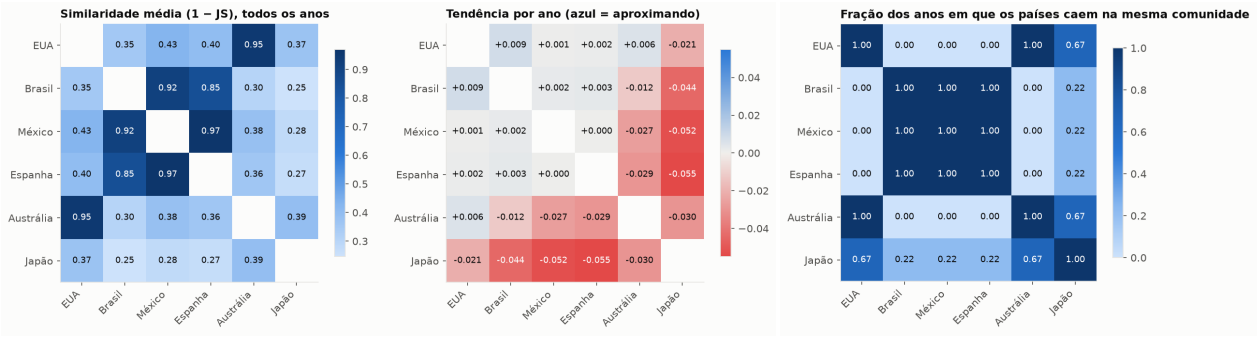


Figura 3: Esquerda: similaridade média ($1-\text{JS}$) por par e tendência anual (azul = aproximando, vermelho = afastando). Direita: fração dos anos em que cada par cai na mesma comunidade de Louvain.

3.4 Hipóteses H1 e H2

H1 não é confirmada. S_{H1} fica entre 0,58 e 0,71 sem tendência (inclinação $+0{,}003$, IC $[-0{,}008;\ 0{,}015]$, $\rho = 0$), e o cosseno entre 0,935 e 0,947 sem tendência (Figura 4). Há alta similaridade, mas ela não aumenta. Além disso, o bloco é heterogêneo: EUA–Brasil, EUA–México e EUA–Espanha ficam em 0,35 a 0,43, enquanto Brasil–México–Espanha formam o núcleo coeso. **H2 é confirmada em $1-$JS.** S_{H2} cai de 0,63 em 2017 para 0,36 em 2018 e chega a 0,19–0,24 de 2022 a 2025, com inclinação de $-0{,}041$ por ano (IC $[-0{,}054;\ -0{,}026]$, $\rho = -0{,}85$, $p = 0{,}004$). O resultado resiste à exclusão de 2017 ($-0{,}024$, IC $[-0{,}042;\ -0{,}005]$) e ao uso apenas de músicas exclusivas ($-0{,}023$, IC $[-0{,}037;\ -0{,}009]$). No cosseno, a queda é nítida de 0,95 para 0,84–0,88, mas sem tendência clara depois de 2017.

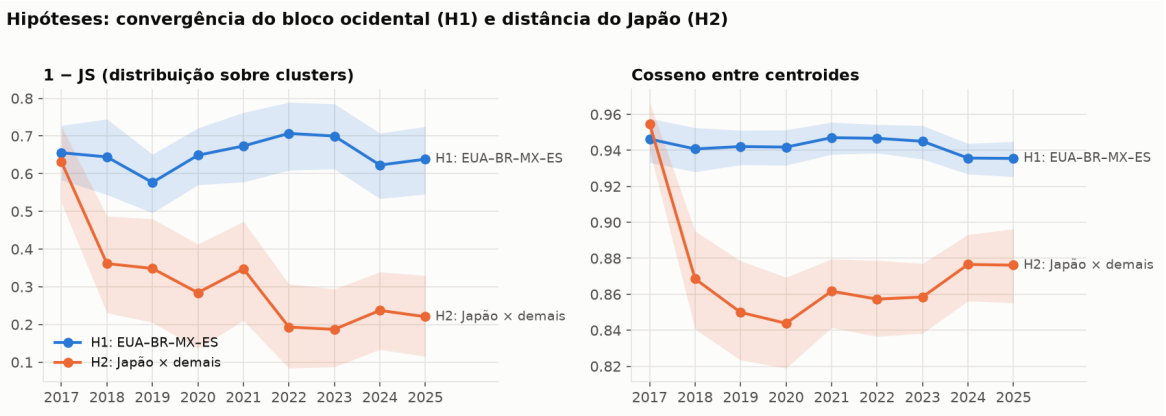


Figura 4: H1 (EUA–Brasil–México–Espanha) e H2 (Japão × demais), com IC95% por bootstrap.

3.5 Controle: hits compartilhados

A fração das músicas do top 40 presentes em dois ou mais países no mesmo ano cai de 52% em 2017 para 23% em 2024 e 26% em 2025 (Figura 5). Músicas presentes em quatro ou mais países passam de 6 em 2017 para nenhuma em 2024. Como músicas compartilhadas caem no mesmo cluster por construção, parte da similaridade alta de 2017 vem delas. Com apenas músicas exclusivas, a similaridade é menor (0,46 em 2017 e 0,39 em 2025) e a curva é mais plana: a inclinação de S_t é $-0{,}0085$ por ano (IC $[-0{,}018;\ 0{,}002]$, $\rho = -0{,}60$, $p = 0{,}09$), sem tendência clara. Isso é compatível com a leitura de que a queda global reflete principalmente a redução dos hits globais, e não um distanciamento do repertório local. A relação é correlacional, pois os dados não permitem identificar causalidade.

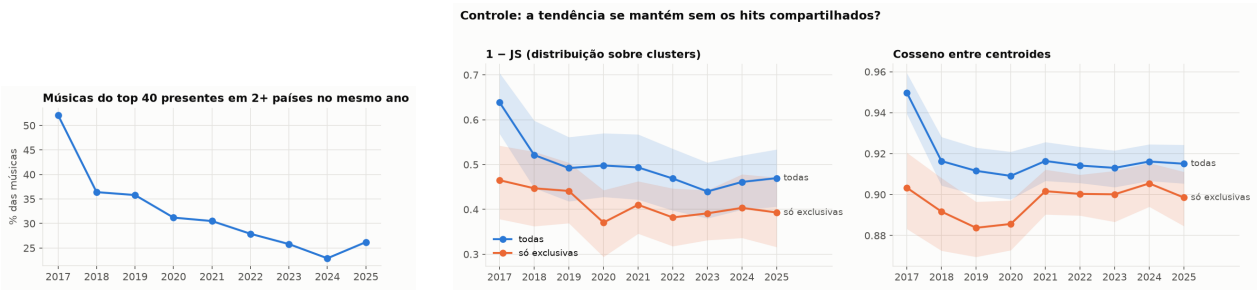


Figura 5: Esquerda: % das músicas do top 40 em 2+ países no mesmo ano. Direita: S_t com todas as músicas e só com as exclusivas.

3.6 Robustez: letras traduzidas para o inglês

Com as letras traduzidas, a similaridade sobe em todos os anos (1−JS global de 0,61 a 0,85, contra 0,44 a 0,64 no original; Figura 6), o que mostra que o idioma separa os clusters. A divergência global desaparece (−0,005, IC [−0,013; 0,003]) e, sem 2017, surge convergência fraca (+0,011, IC [0,001; 0,021]). O resultado mais relevante é H1, que passa a mostrar convergência (+0,014 por ano, IC [0,005; 0,023], $\rho = 0{,}82$; +0,020 sem 2017), e que se mantém com músicas exclusivas (+0,022, IC [0,010; 0,035]; cosseno +0,004, $p = 0{,}002$). Já a distância do Japão persiste, mas com menos sustentação: S_{H2} traduzida é sempre bem menor que S_{H1} (0,18 a 0,45 contra 0,75 a 0,89), porém a inclinação (−0,035) só é sustentada pelo bootstrap ($p = 0{,}19$) e some sem 2017 (+0,001), pois a similaridade se recupera de 0,18 em 2022 para 0,42 em 2025. A Tabela 2 resume as tendências.

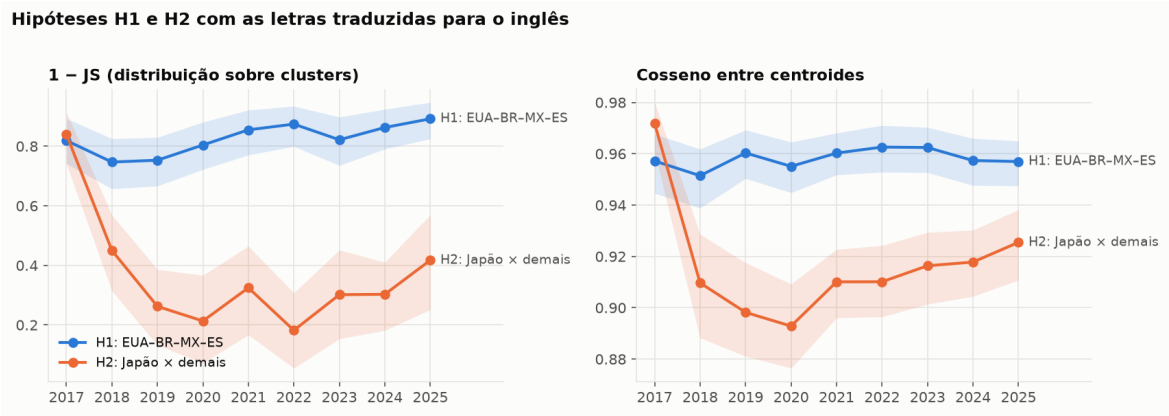


Figura 6: H1 e H2 com letras traduzidas para o inglês.

Tabela 2: Inclinação anual de $1 - \mathrm{JS}$ ($\times 10^{-2}$) com IC95% por bootstrap. *div.* = divergência, *conv.* = convergência, *f.* = fraca (só o IC exclui zero), *s/t* = sem tendência clara.

Série	Letras originais	Letras traduzidas
Global	−1,65 [−2,50; −0,77] **div.**	−0,47 [−1,27; 0,28] s/t
Global sem 2017	−0,85 [−1,91; 0,21] s/t	+1,12 [0,11; 2,10] conv. f.
H1	+0,29 [−0,76; 1,48] s/t	+1,41 [0,48; 2,27] **conv.**
H1 sem 2017	+0,45 [−0,89; 1,91] s/t	+1,95 [0,77; 3,07] **conv.**
H1 só exclusivas	+0,94 [−0,32; 2,27] s/t	+2,20 [0,96; 3,48] **conv.**
H2	−4,05 [−5,43; −2,57] **div.**	−3,47 [−5,12; −1,85] div. f.
H2 sem 2017	−2,37 [−4,16; −0,50] **div.**	+0,12 [−2,10; 2,21] s/t
H2 só exclusivas	−2,28 [−3,65; −0,85] **div.**	−2,47 [−4,17; −0,69] div. f.
Global só exclusivas	−0,85 [−1,80; 0,15] s/t	+0,36 [−0,61; 1,33] s/t

4. Discussão e Limitações

Os resultados não sustentam a ideia de homogeneização semântica global das letras. Os países permanecem muito mais distintos do que o acaso, e a distância é organizada principalmente por idioma e região (blocos latino, anglófono e japonês). A queda da similaridade global se concentra em 2017, quando mais da metade das músicas era compartilhada, e depois se estabiliza. O contraste entre letras originais e traduzidas é a parte mais informativa: quando o idioma é neutralizado, o bloco ocidental (H1) se aproxima, enquanto a distância do Japão é menos clara, embora continue grande. Em termos de H1 e H2, isso sugere que H1 é uma convergência de conteúdo que o idioma esconde, e que H2 é em boa parte (mas não só) um efeito de idioma.

As limitações são várias. (i) São apenas nove pontos no tempo e seis países, e o resultado depende de 2017. (ii) Os clusters refletem sobretudo idioma, e $k = 5$ está no limite da busca, o que favorece partições grosseiras. (iii) As métricas por cluster perdem nuances: o cosseno entre centroides varia pouco (0,89 a 0,95) e discrimina pouco. (iv) Os termos dos clusters têm ruído (por exemplo, palavras de parada) e a tradução automática pode introduzir artefatos próprios. (v) Os rankings do Spotify refletem o consumo na plataforma, e as letras capturam só uma dimensão da cultura. (vi) Os IC por bootstrap consideram só a variabilidade amostral das músicas, e a cobertura de letras pode variar entre países. Os resultados são exploratórios.

5. Conclusão

Não há evidência de que as letras populares do Spotify estejam convergindo globalmente: a similaridade entre países cai, em grande parte por conta do declínio dos hits compartilhados, e o Japão se afasta dos demais. Contudo, com o idioma neutralizado pela tradução, EUA, Brasil, México e Espanha mostram convergência semântica moderada, mesmo só com músicas exclusivas. Em resumo, a diferença cultural medida nas letras é majoritariamente linguística, e a aproximação temática, quando existe, é discreta e restrita ao bloco ocidental.

Referências

[1] Bello, P. and Garcia, D. (2021). Cultural divergence in popular music: the increasing diversity of music consumption on Spotify across countries. *Humanities and Social Sciences Communications*, 8.

[2] Feng, F. et al. (2022). Language-agnostic BERT sentence embedding. In *ACL 2022*.

[3] Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*.

[4] Mauch, M. et al. (2015). The evolution of popular music: USA 1960–2010. *Royal Society Open Science*, 2(5).

[5] Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *EMNLP-IJCNLP 2019*.

[6] Serrà, J. et al. (2012). Measuring the evolution of contemporary western popular music. *Scientific Reports*, 2.

Uso de IA Generativa em Cada Etapa do Projeto

Ferramenta. Claude (Anthropic), em interface de chat, em outubro e novembro de 2026, na proposta, no código e na redação do relatório. Em todas as etapas, a IA foi usada como auxílio.

Etapa	Contribuição da IA	Decisão e validação do grupo
Tema, hipóteses e proposta (outubro)	Avaliou a viabilidade do tema, sugeriu fontes de dados, referências, medidas de similaridade, clusterização, controles e desenho amostral, e redigiu as hipóteses H1 e H2 e um rascunho da proposta (detalhado na proposta entregue).	Tema e pergunta definidos pelo grupo; referências conferidas em bases acadêmicas; hipóteses tratadas como exploratórias.
Coleta de dados, embeddings e código de análise	Auxiliou na escrita do código e no uso de bibliotecas para gerar os embeddings, fazer a clusterização e calcular as similaridades. Não foram treinados modelos de aprendizado de máquina próprios.	Código validado manualmente pelo grupo. Decisões técnicas (países, anos, k, métricas e controles) tomadas pelos integrantes.
Interpretação dos resultados	Recebeu os arquivos de resultados (tabelas CSV e figuras) e a proposta. Leu os números, comparou-os com as hipóteses, propôs a narrativa (divergência global concentrada em 2017 e associada à queda de hits compartilhados; contraste entre letras originais e traduzidas) e apontou ressalvas, como a troca da Coreia do Sul pela Austrália, $k = 5$ no limite da busca e ruído nos termos dos clusters.	O grupo conferiu os valores e os resultados, discutiu a interpretação e produziu mais de uma versão até chegar à versão final.
Redação e formatação do relatório	Gerou o rascunho do relatório em LaTeX, com as tabelas e a seleção das figuras, respeitando o limite de cinco páginas.	Texto revisado e ajustado pelo grupo ao longo de mais de uma versão.

Limitações e responsabilidade. Modelos de IA generativa podem cometer erros, inclusive em interpretações e em números. Os valores reportados neste relatório foram extraídos dos arquivos de resultados produzidos pelo grupo, e a IA não gerou nem alterou dados. A IA atuou como auxílio, e as decisões técnicas foram dos integrantes. O grupo é integralmente responsável pelo conteúdo deste documento.